TECH CHALLENGE - FASE 1
Sistema Inteligente de Suporte ao Diagnostico Medico (Classificacao de Cancer de Mama com Machine Learning e SHAP)

Autor(a): Isaac Figueiredo

LINKS OFICIAIS DE ENTREGA (REPOSITORIO GIT E VIDEO DE DEMONSTRACAO)

- Link do Repositorio Git (Codigo, Dockerfile, README, Notebook): https://github.com/Figueiredoisaac/postech-tech-challenge-fase1
- Link do Video de Demonstracao (YouTube / Vimeo - ate 15 min): https://youtu.be/0msh19j3a9A
- Dataset Publico Utilizado: Breast Cancer Wisconsin (Diagnostic) - UCI / Kaggle (https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data/data)

1. Contextualizacao e Problema Clinico

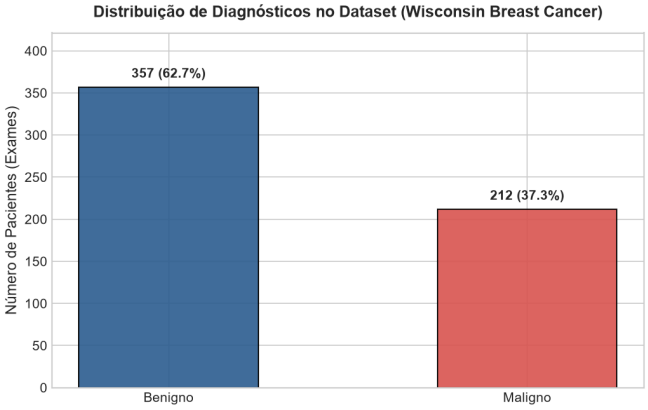
Um grande hospital universitario enfrenta volume crescente de pacientes e exames, demandando solucoes de Inteligencia Artificial que acelerem a triagem clinica e reduzam erros diagnosticos. Nesta primeira fase, desenvolvemos a base do Sistema de Suporte a Decisao Clinica (CDSS) voltado ao diagnostico de Cancer de Mama a partir de dados tabulares extraidos de imagens digitalizadas de biopsias por Puncao Aspirativa por Agulha Fina (PAAF / FNA).

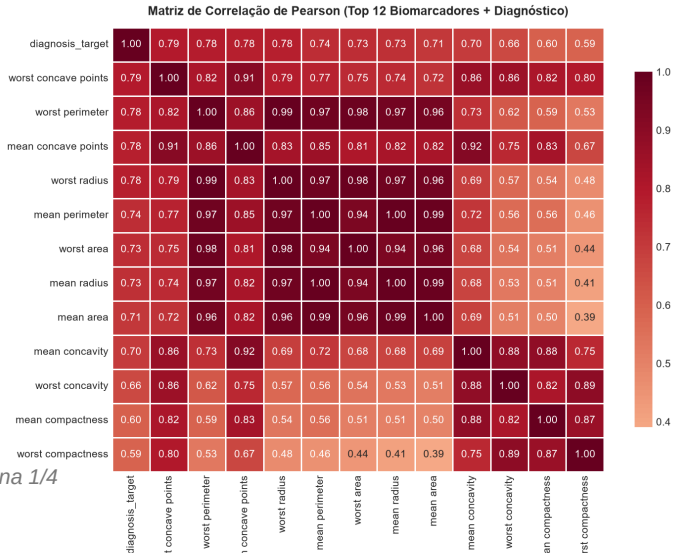
A base Breast Cancer Wisconsin (Diagnostic) possui 569 exames clinicos e 30 variaveis morfometricas continuas que descrevem propriedades dos nucleos celulares (raio, textura, perimetro, area, suavidade, compacidade, concavidade, pontos concavos, simetria e dimensao fractal, calculados em media, erro padrao e pior valor/extremo). A variavel alvo classifica cada exame em:

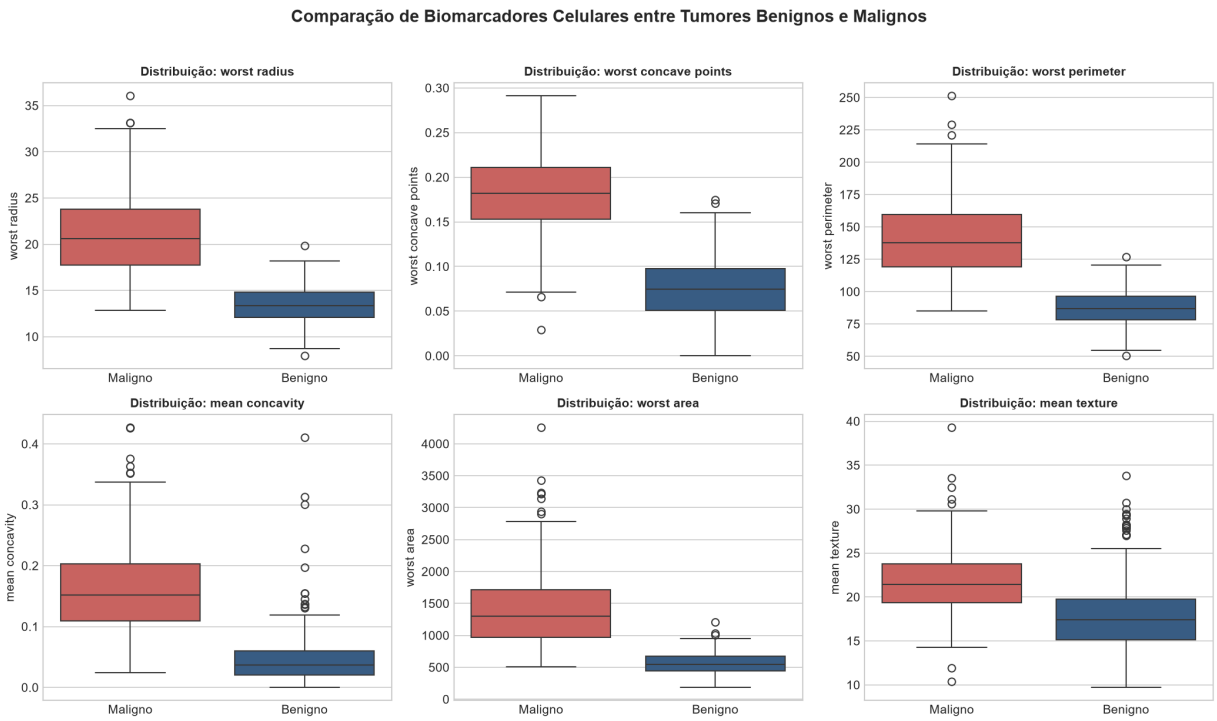
* **Maligno (Classe 1 - Positivo para Doenca):** 212 pacientes (37,26% da base).
* **Benigno (Classe 0 - Ausencia de Malignidade):** 357 pacientes (62,74% da base).

2. Exploracao de Dados (EDA) e Analise de Correlacao

A exploracao estatistica revelou ausencia de valores nulos ou registros duplicados nos 569 prontuarios. A analise das distribuicoes demonstra forte separacao morfologica entre tumores benignos e malignos: lesoes malignas apresentam valores significativamente superiores em 'worst radius' (media de 21,13 mm nos malignos contra 13,38 mm nos benignos), 'worst perimeter' e 'worst concave points'. Na matriz de correlacao de Pearson, os biomarcadores com maior correlacao positiva com a malignidade sao: 'worst concave points' (r = 0,79), 'worst perimeter' (r = 0,78), 'mean concave points' (r = 0,78) e 'worst radius' (r = 0,78).







3. Estrategias de Pre-processamento e Pipeline em Python

Para garantir rigor metodologico e impedir qualquer vazamento de dados (data leakage) entre os conjuntos de treinamento e avaliacao, implementamos um Pipeline estruturado com scikit-learn (ColumnTransformer + Pipeline):

* **Separacao Clara e Estratificada (Treino, Validacao e Teste):** O dataset foi dividido mantendo a proporcao exata de 37,3% de casos malignos em tres subconjuntos independentes: Treino (70% - 398 exames), Validacao (15% - 85 exames) e Teste Cego (15% - 86 exames).

* **Limpeza e Imputacao Preventiva (SimpleImputer):** Inclusao de imputacao mediana para variaveis numericas e moda para variaveis categoricas no pipeline, garantindo resiliencia em producao caso um equipamento laboratorial omita alguma medicao.

* **Conversao e Padronizacao (StandardScaler e OneHotEncoder):** Como as variaveis possuem ordens de grandeza muito distintas (ex.: 'worst area' chega a 4254, enquanto 'smoothness' e da ordem de 0,09), aplicamos padronizacao Z-score (media 0 e desvio padrao 1) ajustada exclusivamente no Treino. No Notebook Jupyter demonstramos tambem a codificacao de faixas categoricas via OneHotEncoder.

4. Modelos Utilizados e Justificativa Tecnica

Treinamos e comparamos cinco algoritmos de classificacao supervisionada com naturezas matematicas complementares:

* **1. Regressao Logistica (class_weight='balanced'):** Modelo linear probabilistico altamente calibrado e interpretavel, ideal para fronteiras de decisao no espaco padronizado.

* **2. Random Forest Classifier (200 arvores):** Ensemble via bagging que captura interacoes nao-lineares entre biomarcadores e e robusto a multicolinearidade.

* **3. Gradient Boosting Classifier:** Ensemble sequencial baseado em boosting de gradiente, focado na correcao iterativa de erros residuais.

* **4. KNN (K-Nearest Neighbors, k=7 ponderado pela distancia):** Classificador baseado em similaridade geometrica local entre prontuarios de pacientes no espaco multidimensional.

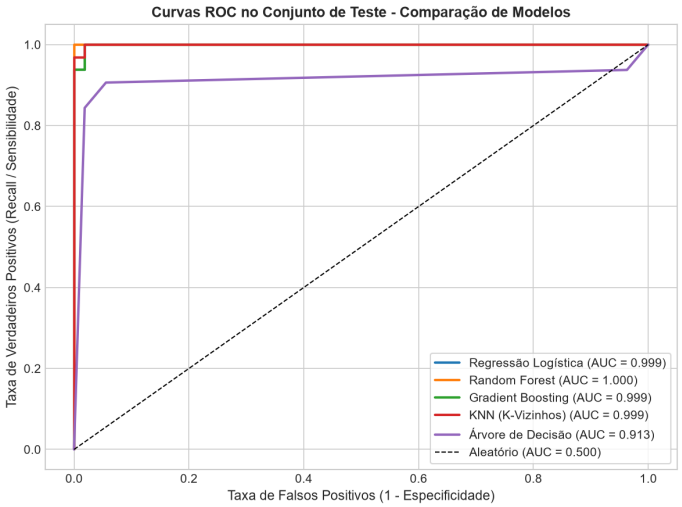
* **5. Arvore de Decisao (Decision Tree):** Modelo base de regras hierarquicas diretas para comparacao de linha de base (baseline).

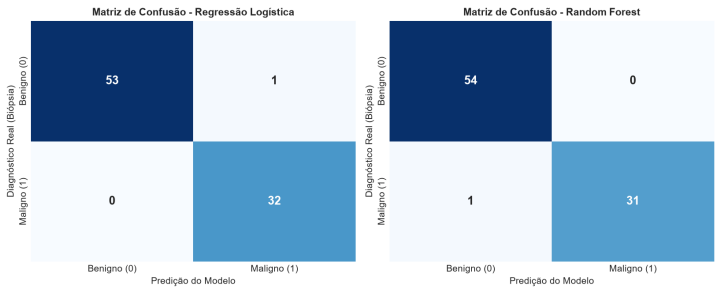
5. Avaliacao dos Modelos e Discussao da Escolha das Metricas

No dominio medico oncologico, os erros de classificacao possuem consequencias assimetricas criticas:
- Falso Positivo (Erro Tipo I): Um nodulo benigno recebe alerta de suspeita e passa por revisao prioritaria do medico patologista. Gera custo de revisao, mas nao coloca a vida do paciente em risco.
- Falso Negativo (Erro Tipo II): Um tumor MALIGNO e classificado como benigno. Isso pode postergar a biopsia confirmativa e o tratamento oncologico, agravando drasticamente o prognostico do paciente.

Por esse motivo, o Recall (Sensibilidade = VP / [VP + FN]) e a metrica primordial de seguranca clinica, apoiada pelo F1-Score (media harmonica entre Precision e Recall) e pela area sob a curva ROC (ROC-AUC).

Modelo	Accuracy	Recall (Sens.)	Precision	F1-Score	ROC-AUC	CV Recall
Regressao Logistica	98,84%	100,00% (32/32)	96,97%	98,46%	0,9988	95,93%
Random Forest	98,84%	96,88% (31/32)	100,00%	98,41%	1,0000	93,86%
Gradient Boosting	96,51%	93,75% (30/32)	96,77%	95,24%	0,9988	90,46%
KNN (K-Vizinhos)	96,51%	90,62% (29/32)	100,00%	95,08%	0,9994	92,51%
Arvore de Decisao	93,02%	90,62% (29/32)	90,62%	90,62%	0,9126	91,84%





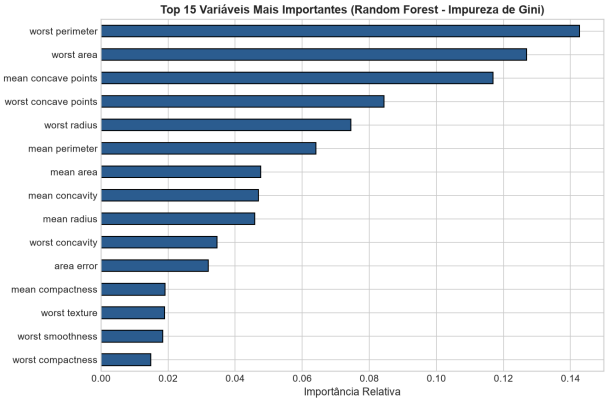
Destaque dos Resultados: A Regressao Logistica atingiu 100% de Recall no conjunto de teste (identificou corretamente todos os 32 casos malignos, com zero falsos negativos e apenas 1 falso positivo em 54 benignos) e 98,84% de Accuracy. O Random Forest alcancou ROC-AUC perfeito (1,0000), 100% de Precision e 98,84% de Accuracy.

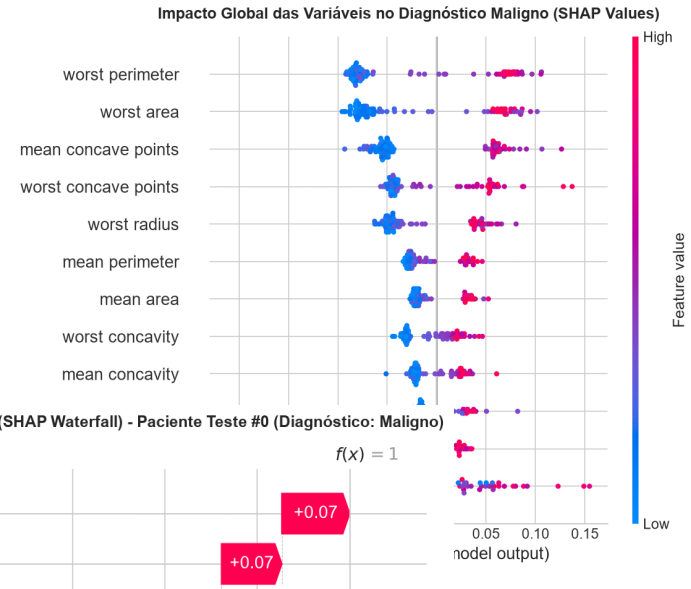
6. Interpretacao dos Resultados (Feature Importance e SHAP)

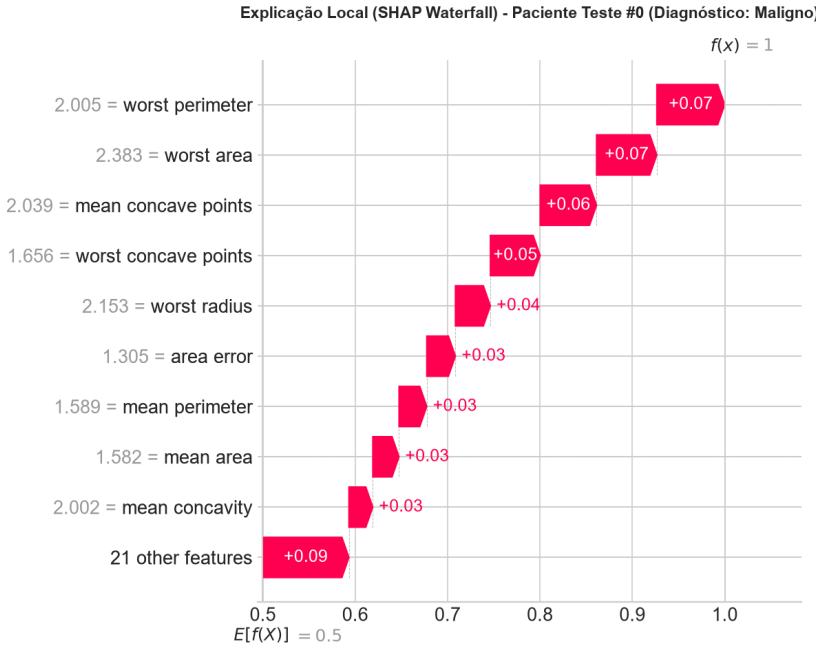
Para eliminar o efeito 'caixa-preta' e fornecer transparencia clinica ao medico, aplicamos Feature Importance (Impureza de Gini no Random Forest) e valores SHAP (SHapley Additive exPlanations):

* **Visao Global (Feature Importance & SHAP Beeswarm):** As variaveis mais determinantes para malignidade sao 'worst perimeter', 'worst area', 'mean concave points', 'worst concave points' e 'worst radius'. No grafico SHAP Beeswarm (pontos vermelhos a direita), valores elevados de pontos concavos e dimensoes nucleares extremas deslocam fortemente a predicao para maligno.

* **Explicacao Local por Paciente (SHAP Waterfall):** Decomposicao individual de quanto cada biomarcador do paciente somou ou subtraiu da probabilidade base.







7. Discussao Critica: Aplicacao Pratica e Papel do Medico

O modelo pode ser utilizado na pratica hospitalar? Sim, integrado como Sistema de Suporte a Decisao Clinica (CDSS):
1. Fluxo Operacional de Triagem: Ao concluir a morfometria digital da lamina de PAAF, o pipeline atribui um Score de Prioridade Oncologica. Exames com probabilidade >= 0,40 recebem marcacao de urgencia na fila do patologista.
2. Segunda Opiniao Auditavel: No Dashboard interativo (Streamlit) desenvolvido neste projeto, o medico inspeciona a probabilidade e o grafico SHAP individual do paciente, prevenindo erros por fadiga em rotinas de alto volume.
3. Soberania Medica (Human-in-the-Loop): O modelo avalia apenas variaveis citologicas. A correlacao com exame fisico, imagem (BI-RADS), historico familiar e imuno-histoquimica e indispensavel - o medico sempre tem a palavra final.